چالش آماری علم داده، ترم ۳ (شماره ۳)

فایل داده: bank_season3_part2.csv شامل ۶۰۰ مشتری یک بانک

هر کد، نمودار، خروجی و توضیح را در یک گزارش تحویل دهید. هر انتخاب آماری باید توجیه شود. بدون توجیه نمره‌ی کامل داده نمی‌شود. بخش‌های «مفهومی» را با استدلال ریاضی/آماری پاسخ دهید و نیازی به کد ندارند (پاسخ به صورت دستی نگارش شود). استفاده از هر نرم‌افزاری (R یا Python) آزاد است. در بخش‌هایی که تصادفی‌اند (اعتبارسنجی متقاطع، بوت‌استرپ، جایگشت) seed ثابت به کار ببرید و آن را گزارش کنید. اعداد شما ممکن است با پاسخنامه اندکی تفاوت داشته باشد؛ ملاک، درستی روش و سازگاری نتیجه‌گیری‌هاست.

در این دو سؤال، برازش فقط روی زیرمجموعه train و ارزیابی روی test انجام می‌شود. پاسخ $y = \text{log_avg_balance}$ است.

متغیرها

ستون	توضیح
customer_id	شناسه مشتری
split	train(۱۵۰ مشتری) یا test (۴۵۰ مشتری)
age, tenure_years, n_products	سن (سال)، سابقه مشتری بودن (سال)، تعداد محصولات فعال
branch_type	نوع شعبه:Metro ، Town یا Rural (سطح مبنا:Metro)
salary_inflow_rial	میانگین ماهانه واریز حقوق (**ریال**)
total_inflow_mrial, avg_monthly_credit_mrial, declared_income_mrial	میانگین ماهانه کل واریزی‌ها، گردش بستانکار و درآمد اظهارشده (میلیون ریال)
card_spend_total_mrial, card_spend_online_mrial, card_spend_pos_mrial	هزینه کارتی ماهانه: کل، آنلاین، پوز (میلیون ریال)
n_card_tx	تعداد تراکنش‌های کارتی ماهانه
mobile_logins, branch_visits, atm_withdrawals	تعداد ماهانه ورود به همراه‌بانک، مراجعه حضوری و برداشت از خودپرداز
credit_limit_mrial	سقف اعتبار (میلیون ریال)
credit_utilization	نسبت استفاده از اعتبار (بین ۰ و ۱)
savings_ratio	نسبت پس‌انداز به درآمد
loan_balance_mrial	مانده تسهیلات (میلیون ریال؛ صفر یعنی فاقد تسهیلات)
score_01تاscore_10	ده امتیاز رفتاری ناشناس (استانداردشده)
exposure_months	طول دوره مشاهده مشتری (ماه)
n_overdraft	تعداد رویدادهای اضافه‌برداشت در دوره مشاهده
avg_overdraft_mrial	**میانگین** مبلغ رویدادهای اضافه‌برداشت (میلیون ریال)؛ فقط برای مشتریان با n_overdraft > 0
log_avg_balance	لگاریتم طبیعی میانگین مانده حساب (پاسخ سؤال‌های ۱ و ۲)

سوال ۱ (۳۰ نمره): Ridge، Lasso و Net Elastic

برای این سوال موارد زیر را در نظر بگیرید:

- ستون‌های X را با میانگین و انحراف معیار نمونه‌ای مجموعه آموزش، استاندارد کنید (تبدیل برای آزمون). پاسخ در Ridge مرکزی می‌شود و عرض از مبدأ جریمه نمی‌شود. توابع هدف:

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \underset{\beta}{\text{argmin}} \ \| y - X\beta \|_2^2 + \lambda \| \beta \|_2^2$$

$$\hat{\beta}_{\lambda,\alpha}^{\text{EN}} = \underset{\beta_0,\beta}{\text{argmin}} \ \frac{1}{2n} \| y - \beta_0 \mathbf{1} - X\beta \|_2^2 + \lambda \left[\alpha \| \beta \|_1 + \frac{1-\alpha}{2} \| \beta \|_2^2 \right]$$

که $\alpha = 1$ همان Lasso و $\alpha = 0.5$ همان Elastic Net است.

- اعتبارسنجی متقاطع ۱۰-تایی با shuffle و seed ثابت
- $\lambda_{\min}$ کمینه خطای CV و λ_{1se} بزرگ‌ترین λ با خطای CV کمتر از «کمینه + یک خطای معیار» است.
- شبکه λ برای Ridge: ۱۰۰ نقطه لگاریتمی از ۰/۰۱ تا ۱۰۰۰
- برای Lasso و Elastic Net: مسیر پیش‌فرض با ۱۰۰ نقطه (eps = 1e-3).

الف) (۱۰ نمره): چرا استانداردسازی، پیش از منظم‌سازی ضروری است؟ با اشاره به ستون salary_inflow_rial توضیح دهید. سپس، فاکتور تورم واریانس (VIF) را برای همه ۳۰ پیش‌بین روی train حساب و شش مقدار بزرگ‌تر را گزارش کنید. بعد از آن، نسبت بزرگ‌ترین به کوچک‌ترین مقدار ویژه X^TX (استانداردشده) را گزارش کنید. سپس، مدل OLS کامل را برازش دهید و MSE آموزش و آزمون را گزارش کنید. در انتها، ضرایب OLS چهار متغیر درآمدی را بنویسید و درباره علامت‌ها و اندازه آن‌ها نظر دهید.

ب) (۵ نمره): Ridge را با CV برازش دهید. $\lambda_{\min}$ و λ_{1se}، MSE آزمون در هر دو، و درجه آزادی مؤثر

$$\text{df}(\lambda) = \text{tr}[X(X^TX + \lambda I)^{-1}X^T]$$

را در هر دو λ گزارش کنید. ضرایب چهار متغیر درآمدی را در OLS و Ridge (در $\lambda_{\min}$) مقایسه و تفسیر کنید.

ج) (۱۰ نمره): Lasso و Elastic Net را با CV برازش دهید. برای هر کدام در $\lambda_{\min}$،

- تعداد ضرایب غیرصفر، تعداد متغیرهای score _* که وارد مدل شده‌اند، MSE آزمون را گزارش کرده و سپس مشخص کنید که از چهار متغیر درآمدی و چهار متغیر هزینه کارتی (card_spend_total_ mrial ، card_spend_online_mria ، card_spend_pos_ mrial، n_card_tx)، کدام‌ها غیرصفرند.
- ترتیب ورود شش متغیر نخست در مسیر منظم‌سازی Lasso را بنویسید.
- ۱۰۰ نمونه بوت‌استرپ از train بگیرید (نمونه‌گیری با جایگذاری، هر بار LassoCV با ۵ فولد) و فراوانی انتخاب هر یک از آن هشت متغیر درآمدی و هزینه کارتی (چهار متغیر درآمدی و چهار متغیر هزینه کارتی که بالاتر نام برده شد) را گزارش کنید؛ این هشت متغیر با شش متغیر نخست مسیر منظم‌سازی یکی نیستند.
- نتیجه را درباره پایداری انتخاب متغیر در Lasso تفسیر کنید. Lasso در λ_{1se} چند متغیر نگه می‌دارد و MSE آزمون آن چقدر است؟

د) (۵ نمره): فرض کنید دو ستون استانداردشده x_j و x_k در X یکسان باشند ($x_j = x_k$)

- نشان دهید جواب Ridge یکتا است و $\hat{\beta}_j = \hat{\beta}_k$.
- با این فرض که ماتریس حاصل از حذف یکی از دو ستون یکسان، رتبه کامل ستونی دارد، نشان دهید در Lasso فقط مجموع $\hat{\beta}_j + \hat{\beta}_k$ تعیین می‌شود و مجموعه جواب‌های بهینه را مشخص کنید.

- فرض کنید اکنون x_j و x_k یکسان نیستند و همبستگی نمونه‌ای‌شان ρ است. برای Ridge ثابت کنید

$$|\hat{\beta}_j - \hat{\beta}_k| \leq \frac{\sqrt{2(n-1)(1-\rho)}}{\lambda} \| y \|_2.$$

- با همان فرض‌های قسمت قبل، برای Elastic Net با $\alpha < 1$ ثابت کنید اگر $\hat{\beta}_j \hat{\beta}_k > 0$ آن‌گاه

$$|\hat{\beta}_j - \hat{\beta}_k| \leq \frac{\sqrt{2(n-1)(1-\rho)}}{\lambda} \| y \|_2.$$

سپس توضیح دهید چرا برای $\alpha = 1$ چنین کرانی به دست نمی‌آید.

سوال ۲ (۲۰ نمره): مقایسه و انتخاب مدل

مدل‌های تودرتوی زیر را روی train با OLS برازش دهید (تعداد شیب‌ها k و تعداد پارامترها $k+1$) :

- **M0:** فقط عرض از مبدأ
- **M1:** age, tenure_years, n_products, Town, Rural
- **M2:** M1 + total_inflow_mrial
- **M3:** M2 + card_spend_total_mrial
- **M4:** M3 + savings_ratio, credit_utilization, mobile_logins, loan_balance_mrial, branch_visits, atm_withdrawals, credit_limit_mrial
- **M5:** مدل کامل (۳۰ پیش‌بین)

معیارها (ثابت‌های جمعی حذف شده‌اند؛ اگر نرم‌افزار شما ثابت دیگری دارد، فقط تفاضل‌ها مهم‌اند):

$$\mathrm{AIC} = n\ln\frac{\mathrm{RSS}}{n} + 2(k+1), \qquad \mathrm{BIC} = n\ln\frac{\mathrm{RSS}}{n} + (k+1)\ln n, \qquad C_p = \frac{\mathrm{RSS}}{\hat{\sigma}^2_{\mathrm{M5}}} - n + 2(k+1)$$

الف) (۵نمره): برای هر جفت متوالی ($\mathrm{M_{i-1}} \subset \mathrm{M_i}$) آماره F جزئی و p-value آن، آماره نسبت درست‌نمایی (LRT) گاوسی $n\ln(\mathrm{RSS_{i-1}}/\mathrm{RSS_i})$ و p-value آن (با توزیع χ^2_q) را در یک جدول بیاورید. در کدام جفت‌ها، دو آزمون به‌طور محسوسی اختلاف دارند و چرا؟ آیا افزودن ۱۶ متغیر باقی‌مانده در M5 به M4 توجیه آماری دارد؟

ب) (۵ نمره): برای هر شش مدل RSS، R^2 ، R^2 تعدیل‌شده، AIC، BIC و C_p را گزارش کنید. هر معیار کدام مدل را برمی‌گزیند؟ برای M5 مقدار C_p را توضیح دهید.

ج) (۷ نمره): روی همه ۳۰ پیش‌بین، انتخاب گام‌به‌گام را اجرا کنید:

- پیشرو با AIC، پسرو با AIC، دوطرفه با AIC (شروع از مدل تهی)
- پیشرو با BIC و پسرو با BIC.
- برای هر روش، مجموعه متغیرهای انتخاب‌شده، اندازه، تعداد متغیرهای score_* واردشده، اینکه از گروه‌های درآمدی و هزینه‌ای کدام متغیر انتخاب شده و MSE آزمون را گزارش کنید.
- چرا روش‌های پیشرو و پسرو نمایندگان متفاوتی از گروه‌های هم‌خط برمی‌گزینند؟ MSE آزمون این مدل‌ها را با نتایج سؤال ۱ مقایسه کنید.

د) (۳ نمره): دو مدل تودرتوی گاوسی را در نظر بگیرید: مدل کوچک‌تر با p_0 پارامتر و مدل بزرگ‌تر با p_1 پارامتر. تعداد پارامترهای هر مدل شامل عرض از مبدأ است و σ^2 شمرده نمی‌شود، یعنی مدلی با k شیب $p = k+1$ پارامتر دارد. $q = p_1 - p_0$ تعداد پارامترهایی است که مدل بزرگ‌تر بیشتر دارد.

- ثابت کنید AIC مدل بزرگ‌تر را برمی‌گزیند اگر و فقط اگر

$$F > \frac{n-p_1}{q}\left(e^{2q/n} - 1\right),$$

و کران متناظر BIC را بیابید.

- ثابت کنید وقتی $n \to \infty$ و q ثابت است، AIC معادل آزمونی است که H_0 را در سطح $\alpha_{\mathrm{AIC}}(q) = P(\chi^2_q > 2q)$ رد می‌کند، و مقدار آن را برای $q = 1,2,3,5,10,20$ حساب کنید. چرا BIC برخلاف AIC سازگار (consistent) است؟

- ثابت کنید C_p مدل بزرگ‌تر را برمی‌گزیند اگر و فقط اگر F جزئی‌ای که مخرج آن $\hat{\sigma}^2_{\mathrm{M5}}$ است، از ۲ بزرگ‌تر باشد.