چالش آماری علم داده، ترم ۳ (شماره ۴)

فایل داده: bank_season3_part2.csv شامل ۶۰۰ مشتری یک بانک

هر کد، نمودار، خروجی و توضیح را در یک گزارش تحویل دهید. هر انتخاب آماری باید توجیه شود. بدون توجیه نمره‌ی کامل داده نمی‌شود. بخش‌های «مفهومی» را با استدلال ریاضی/آماری پاسخ دهید و نیازی به کد ندارند (پاسخ به صورت دستی نگارش شود). استفاده از هر نرم‌افزاری (R یا Python) آزاد است. در بخش‌هایی که تصادفی‌اند (اعتبارسنجی متقاطع، بوت‌استرپ، جایگشت) seed ثابت به کار ببرید و آن را گزارش کنید. اعداد شما ممکن است با پاسخنامه اندکی تفاوت داشته باشد؛ ملاک، درستی روش و سازگاری نتیجه‌گیری‌هاست.

متغیرها

ستون	توضیح
customer_id	شناسه مشتری
age, tenure_years, n_products	سن (سال)، سابقه مشتری بودن (سال)، تعداد محصولات فعال
branch_type	نوع شعبه:Metro ، Town یا Rural (سطح مبنا:Metro)
salary_inflow_rial	میانگین ماهانه واریز حقوق (**ریال**)
total_inflow_mrial, avg_monthly_credit_mrial, declared_income_mrial	میانگین ماهانه کل واریزی‌ها، گردش بستانکار و درآمد اظهارشده (میلیون ریال)
card_spend_total_mrial, card_spend_online_mrial, card_spend_pos_mrial	هزینه کارتی ماهانه: کل، آنلاین، پوز (میلیون ریال)
n_card_tx	تعداد تراکنش‌های کارتی ماهانه
mobile_logins, branch_visits, atm_withdrawals	تعداد ماهانه ورود به همراه‌بانک، مراجعه حضوری و برداشت از خودپرداز
credit_limit_mrial	سقف اعتبار (میلیون ریال)
credit_utilization	نسبت استفاده از اعتبار (بین ۰ و ۱)
savings_ratio	نسبت پس‌انداز به درآمد
loan_balance_mrial	مانده تسهیلات (میلیون ریال؛ صفر یعنی فاقد تسهیلات)
score_01تاscore_10	ده امتیاز رفتاری ناشناس (استانداردشده)
exposure_months	طول دوره مشاهده مشتری (ماه)
n_overdraft	تعداد رویدادهای اضافه‌برداشت در دوره مشاهده
avg_overdraft_mrial	**میانگین** مبلغ رویدادهای اضافه‌برداشت (میلیون ریال)؛ فقط برای مشتریان با n_overdraft > 0
log_avg_balance	لگاریتم طبیعی میانگین مانده حساب (پاسخ سؤال‌های ۱ و ۲)

سؤال ۱ (۳۰ نمره): رگرسیون شمارشی: پواسون و دوجمله‌ای منفی

برای این سوال موارد زیر را در نظر بگیرید:

- ✓ از هر ۶۰۰ مشتری استفاده کنید.
- ✓ y_i برابر n_overdraft (تعداد اضافه‌برداشت مشتری i) و t_i برابر exposure_months (طول دوره مشاهده) است.
- ✓ مدل مبنا:

$y_i \sim \text{Poisson}(\mu_i)$ where
$\ln\mu_i = \ln t_i + \beta_0 + \beta_1\,\text{util}_i + \beta_2\,\text{atm}_i + \beta_3\,\text{visits}_i + \beta_4\,\text{sav}_i + \beta_5\,\text{age}_i + \beta_6 \ln(\text{inflow}_i)$ where
- util = credit_utilization
- atm = atm_withdrawals
- visits = branch_visits
- sav = savings_ratio
- inflow = total_inflow_mrial

- ✓ جمله $\ln t_i$ یک offset است (ضریب آن ثابت و برابر ۱).
- ✓ برای مدل پواسون برازش‌شده:

$$X^2 = \sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i}, \qquad \hat{\phi} = \frac{X^2}{n-p}$$

- ✓ سه فرض واریانس که در این سؤال مقایسه می‌شوند:

پواسون: $\text{Var}(y_i) = \mu_i$, شبه‌پواسون: $\text{Var}(y_i) = \phi\,\mu_i$, NB2: $\text{Var}(y_i) = \mu_i + \frac{\mu_i^2}{\theta}$

الف) (۱۰ نمره):

- مدل را با پیوند لگاریتمی و offset برازش دهید. جدول ضرایب، خطای معیار و نسبت نرخ $e^{\widehat{\beta}}$ را به دست بیاورید. همچنین انحراف مدل (anceDevi)، انحراف مدل تهی، X^2 و $\hat{\phi}$ را گزارش کنید.
- نشان دهید. $\sum_i y_i = \sum_i \hat{\mu}_i$
- مدل را بدون offset ولی با $\ln t_i$ به‌عنوان یک متغیر معمولی برازش دهید. ضریب آن را گزارش و H_0: $\beta_{\ln t} = 1$ را آزمون کنید.
- مدل را بدون هیچ تعدیل برای مدت مشاهده برازش دهید و ضرایب را با مدل بند (۱) مقایسه کنید.

ب) (۱۰ نمره):

- (۱) $\hat{\phi}$ را گزارش کنید. آزمون کمکی Cameron-Trivedi را اجرا کنید: رگرسیون بدون عرض از مبدأ

$$\frac{(y_i - \hat{\mu}_i)^2 - y_i}{\hat{\mu}_i} = \gamma\,\hat{\mu}_i + u_i$$

و آزمون H_0: $\gamma = 0$.

- چهار خطای معیار را برای هر ضریب بیاورید: پواسون، شبه‌پواسون ($\sqrt{\hat{\phi}}$برابر خطای معیار پواسون)، قوی (HC0) و NB2.
- مدل NB2 را برازش دهید و $\hat{\theta}$ ، likelihood-log و AIC آن و مدل پواسون را گزارش کنید.
- نتایج را در یک جدول مقایسه و تفسیر کنید.

ج) (۲ نمره):

فرض $H_0: \beta_1 = \beta_2 = \beta_3 = 0$ را با در نظر گرفتن $\Delta D = D_0 - D_1$ (مدل کوچک‌تر منهای مدل بزرگ‌تر) و با روش‌های:

- LRT پواسون: $\Delta D \sim \chi^2_q$
- شبه‌درست‌نمایی (با $\hat{\phi}$ از مدل بزرگ‌تر):

$$F = \frac{\Delta D/q}{\hat{\phi}} \sim F_{q,\, n-p}$$

- LRT مدل NB2: $2(\ell_1 - \ell_0) \sim \chi^2_q$

بررسی کرده و آماره‌ها و p-valueها را مقایسه و تفاوت‌ها را توضیح دهید.

د) (۲ نمره):

- مشتریان را بر اساس دهک‌های $\hat{\mu}_i$ مدل پواسون، گروه‌بندی کنید. سپس در هر دهک، چهار مقدار $\bar{\hat{\mu}}$ ،$\bar{y}$ ، $\overline{(y-\hat{\mu})^2}$ و $\overline{\hat{\mu} + \hat{\mu}^2/\hat{\theta}}$ را به دست آورید. کدام تابع واریانس با داده سازگارتر است؟

- پنج مشتری با بزرگ‌ترین |باقی‌مانده انحراف| را با شناسه، y، t، $\hat{\mu}$ ، باقیمانده انحراف و باقیمانده پیرسون معرفی کنید. آیا این‌ها «پرت» هستند یا نشانه نقص مدل؟

ه) (۶ نمره):

- نشان دهید برآوردگر ماکسیمم درست‌نمایی پواسون فقط با درستی مدل میانگین سازگار است (بدون فرض $\mathrm{Var}(y) = \mu$). فرم ساندویچی واریانس حدی آن را بنویسید. نتیجه بگیرید اگر $\mathrm{Var}(y_i) = \phi\mu_i$ آن‌گاه خطای معیار شبه‌پواسون $\sqrt{\hat{\phi}}$ برابر خطای معیار پواسون است.

- نشان دهید برای θ معلوم، NB2 عضو خانواده نمایی است و پیوند کانونی آن را بیابید. توضیح دهید چرا پیوند لگاریتمی کانونی نیست. معادله نمره را برای پیوند لگاریتمی بنویسید و نتیجه بگیرید در NB2 لزوماً $\sum y_i \neq \sum \hat{\mu}_i$.

- برای $H_0: 1/\theta = 0$ (پواسون در برابر NB2) توضیح دهید چرا توزیع حدی LRT برابر $1/2\,\chi^2_0 + 1/2\,\chi^2_1$ است نه χ^2_1 . p-value صحیح را بنویسید.

سؤال ۲ (۲۰ نمره): رگرسیون گاما برای شدت اضافه‌برداشت

برای این سوال موارد زیر را در نظر بگیرید:

- ✓ فقط مشتریانی را نگه دارید که n_overdraft >0 است (n تعداد این مشتریان).
- ✓ برای مشتری i : $n_i = \text{n_overdraft}$ و $y_i = \text{avg_overdraft_mrial}$ میانگین n_i رویداد اضافه‌برداشت است.
- ✓ بردار پیش‌بین (با $p = 8$ پارامتر):

$x_i = (1,\ \ln(\text{limit}_i),\ \ln(\text{inflow}_i),\ \text{util}_i,\ \text{age}_i,\ \ln(\text{card}_i),\ \text{Town}_i,\ \text{Rural}_i)$ where
- limit = credit_limit_mrial
- inflow = total_inflow_mrial
- util = credit_utilization
- card= card_spend_total_mrial

- ✓ مدل گاما:

$$\mathbb{E}(y_i) = \mu_i, \qquad \text{Var}(y_i) = \frac{\phi\,\mu_i^2}{w_i}, \qquad w_i = n_i, \qquad \ln\mu_i = x_i^{\top}\beta$$

و برآورد پراکندگی:

$$X^2 = \sum_i w_i \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i^2}, \qquad \hat{\phi} = \frac{X^2}{n-p}$$

الف) (۴ نمره):

- میانگین، انحراف معیار، چولگی و ضریب تغییرات y و چولگی $\ln y$ را گزارش کنید.
- مدل خطی گاوسی را یک بار روی y و یک بار روی $\ln y$ برازش دهید و R^2 و p-value آزمون Pagan–Breusch را گزارش کنید.
- مدل گامای وزن‌دار را برازش دهید و ضرایب، خطاهای معیار، Deviance و $\hat{\phi}$ را گزارش کنید.
- ضرایب را به زبان اثر ضربی تفسیر و با مدل خطی روی $\ln y$ مقایسه کنید.

ب) (۲ نمره):

فرض H_0: $\beta_{\text{age}} = \beta_{\text{lncard}} = \beta_{\text{Town}} = \beta_{\text{Rural}} = 0$ را با در نظر گرفتن $\Delta D = D_0 - D_1$ و $\hat{\phi}$ از مدل بزرگ‌تر و اطلاعات توزیعی زیر

$$\frac{\Delta D}{\hat{\phi}} \sim \chi^2_q, \qquad F = \frac{\Delta D/q}{\hat{\phi}} \sim F_{q,\,n-p}$$

بررسی کرده و آماره و p-value را گزارش کنید.

ج) (۱۰ نمره):

- نشان دهید برای گامای با پیوند لگاریتمی رابطهٔ زیر برقرار است

$$\sum_i w_i \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i} = 0$$

ولی لزوماً $\sum_i w_i\, y_i \neq \sum_i w_i\, \hat{\mu}_i$ (برخلاف پواسون).

- نسبت «کل مبلغ پیش‌بینی‌شده به کل مبلغ مشاهده‌شده»

$$\frac{\sum_i w_i\, \hat{\mu}_i}{\sum_i w_i\, y_i}$$

را توسط چهار روش زیر حساب کنید. به غیر از روش اول، در تمام روش‌ها، مدل خطی روی $\ln y$ با مقدار برازش‌شده $\hat{\eta}_i$ ، باقی‌مانده‌های $\hat{e}_i$ و واریانس باقی‌مانده $\hat{\sigma}^2$ به کار می‌رود:

- ✓ گامای با پیوند لگاریتمی: $\hat{\mu}_i$ از مدل

- ✓ برگرداندن ساده: $\hat{\mu}_i = e^{\hat{\eta}_i}$
- ✓ اصلاح Duan (smearing): $\hat{\mu}_i = e^{\hat{\eta}_i} \cdot \frac{1}{n}\sum_j e^{\hat{e}_j}$
- ✓ اصلاح نرمال: $\hat{\mu}_i = e^{\hat{\eta}_i + \hat{\sigma}^2/2}$

با استدلال نابرابری ینسن توضیح دهید چرا (ب) سوگیر است.

د) (۴ نمره):

- ثابت کنید اگر $Z_{i1}, \dots, Z_{in_i}$ مستقل و Gamma با شکل ν و میانگین m باشند، میانگین آن‌ها گامای با شکل $n_i\nu$ و میانگین m است. نتیجه بگیرید

$$\mathrm{Var}(y_i) = \frac{\phi\, m^2}{n_i}, \qquad \phi = \frac{1}{\nu},$$

یعنی وزن پیشین $w_i = n_i$ است.

- نشان دهید در پیوند لگاریتمی وزن IRLS برابر w_i و مستقل از μ_i است. اطلاعات فیشر را بنویسید و توضیح دهید چرا $\hat{\beta}$ به ϕبستگی ندارد.

- مدل را یک بار وزن‌دار و یک بار بدون وزن برازش دهید و ضرایب، خطاهای معیار و $\hat{\phi}$ را مقایسه کنید. سپس مشتریان را در سه گروه:$n_i = 1$ ، $n_i \in \{2,3\}$ و $n_i \geq 4$ بگذارید. در هر گروه میانگین مربع باقی‌مانده پیرسون مقیاس‌شده را برای دو مدل بیاورید:

بدون وزن: $\dfrac{y_i - \hat{\mu}_i}{\hat{\mu}_i}$ وزن‌دار: $\sqrt{w_i}\,\dfrac{y_i - \hat{\mu}_i}{\hat{\mu}_i}$

نتیجه را تفسیر کنید.